Tarefa lei de Zipf

> Github Repo: https://github.com/samuelsemmler/Mackenzie-Data-Science

> Colab: https://drive.google.com/file/d/14WVvMFL2hZvmSTKcRMzLjVch9286Z_Xg/view?usp=sharing

Mas afinal, o que é a lei de Zipf?

Clique duas vezes (ou pressione "Enter") para editar

O material escolhido

Abraham Lincoln foi o 16º presidente norte-americano, governando de 1861 a 1865. Foi em seu governo que ocorreu a Guerra Civil Americana, conflito causado pela não aceitação da vitória de Lincoln pelos estados sulistas na eleição presidencial de 1860. Lincoln ficou marcado também como o presidente que decretou a emancipação dos afro-americanos nos Estados Unidos.

Abraham Lincoln deu centenas de discursos em sua vida. Para esta tarefa, foram escolhidos 3 discursos.

Second Inaugural Address (Segundo Discurso Inaugural)

> O segundo discurso inaugural de Lincoln é um dos discursos inaugurais mais curtos de todos os tempos. É considerado por muitos não apenas o maior discurso de posse, mas o maior discurso de qualquer tipo já proferido nos Estados Unidos.

Gettysburg Address

> Vários estados sentiram que seus soldados mereciam um lugar de descanso melhor do que as covas rasas originais no campo de batalha de Gettysburg. O cidadão de Gettysburg, David Wills, convenceu a Pensilvânia a comprar dezessete propriedades do campo de batalha para que os soldados fossem devidamente enterrados. Uma cerimônia de dedicação foi planejada e o famoso orador e ex-presidente de Harvard Edward Everett seria o orador principal. O presidente Lincoln foi convidado a falar como uma reflexão posterior e teve apenas cerca de duas semanas para preparar seus comentários. Aproximadamente 15.000 pessoas estavam presentes para ouvir o discurso de duas horas de Everett e o discurso de dois minutos de Lincoln acabou antes que a maioria da multidão percebesse que ele havia começado.

Farewell Address

> Abraham Lincoln e sua família se mudaram de casa em 8 de fevereiro de 1861 e Jackson em 8 de fevereiro de 1861. Eles ficaram alguns dias no Chenery House Hotel. Em 11 de fevereiro de 1861, um dia antes de seu aniversário de 52 anos, o presidente eleito Lincoln embarcou em um trem inaugural especialmente organizado no Great Western Depot. Antes de o trem partir, Lincoln fez alguns comentários para a multidão em que resumiu seus anos em Springfield e falou sobre a tarefa que tinha pela frente.

Agora que entendemos melhor o que é e como funciona a lei de Zipf e tambem conhecemos melhor o material que vamos trabalhar, vamos iniciar o desenvolvimento de nossa análise sobre o material:

O primeiro passo é importar as bibliotecas

```
1 import requests
2 import re
3 import json
4 import collections
5 import pandas as pd
6 import matplotlib.pyplot as plt
7 import seaborn as sns
```

Com as bibliotecas devidamente importadas, iremos começar a leitura e a tratativa do material escolhido

Para isto, primeiro vamos definir algumas variáveis auxiliares que irão nos ajudar durante o todo desenvolvimento da tarefa

```
INPUT_DIRECTORY = 'resources/input'
OUTPUT_DIRECTORY = 'resources/output'

# Variável para controle de execução local ou colab
#   True: Executa local
#   False: Executa no google colab
LOCAL_EXECUTION = False
```

Ler todo o conteúdo do texto

```
if LOCAL_EXECUTION:
    with open(f'{INPUT_DIRECTORY}/Abraham_Lincoln.txt', 'r') as input_file:
        input_file_data = input_file.read()
else:
    input_file_data = requests.get('https://raw.githubusercontent.com/samuelsemmler/Mac
```

Realizar a tratativa de dados

> Para isto foram criadas três funções diferentes:

---

prepare_data

Função responsável por remover todos os caracteres especiais do texto e por fim deixar todo o texto em caixa baixa (**LOWER CASE**)

---

text_to_list

Função responsável por transformar todo o texto em lista e por fim transformar esta lista em um uma lista contendo elementos **chave / valor** representando as palavras e suas respectivas frequências

---

create_zipf_list

Função responsável por criar uma lista de dicionários contendo cada **palavra**, sua respectiva **frequência** e seu **ranking** / **porcentagem** em relação a todas as outras

palavras na lista

```
def prepare_data(text):
    """
    Esta função é responsável por remover todos os caracteres especiais e nivelar todo
    """
    chars_to_remove = "!\"#$%&'()*+,-./:;<=>?@[\]^_`{|}~0123456789"
    translation_table = str.maketrans("", "", chars_to_remove)

    text = text.translate(translation_table).lower()
    return text.lower()


def text_to_list(text):
    """
    Esta função é responsável por transformar o texto em lista e posteriormente transfo
    """
    words = text.split()
    word_frequencies = collections.Counter(words)

    return word_frequencies.most_common()


def create_zipf_list(frequency_list):
    """
    Cria uma lista de dict com cada palavra, sua respectiva frequência
    e seu ranking / porcentagem mediante todas as outras palavras
    """

    zipf_list = []

    top_frequency = frequency_list[0][1]

    for index, item in enumerate(frequency_list, start=1):

        relative_frequency = "1/{}".format(index)
        zipf_frequency = top_frequency * (1 / index)
        difference_actual = item[1] - zipf_frequency
        difference_percent = (item[1] / zipf_frequency) * 100

        zipf_list.append({"word": item[0],
                          "actual_frequency": item[1],
                          "relative_frequency": relative_frequency,
                          "zipf_frequency": zipf_frequency,
                          "difference_actual": difference_actual,
                          "difference_percent": difference_percent})

    return zipf_list
```

```
clean_text = prepare_data(input_file_data)
frequency_list = text_to_list(clean_text)
zipf_list = create_zipf_list(frequency_list)
```

Trabalhar em cima dos dados coletados

Transformar a lista de dict em um dataframe do pandas

```
df = pd.DataFrame(zipf_list)
```

Mostrar as primeiras linhas do dataset

```
df.head()
```

	word	actual_frequency	relative_frequency	zipf_frequency	difference_actual
0	the	71	1/1	71.000000	0.000000
1	to	37	1/2	35.500000	1.500000
2	and	36	1/3	23.666667	12.333333
3	of	30	1/4	17.750000	12.250000
4	that	28	1/5	14.200000	13.800000

Agora algumas informações sobre o dataset formado

```
print(f"Quantidade total de palavras >> {sum(df['actual_frequency'])}")
print(f"Quantidade total de palavras únicas >> {len(df['word'])}")
```

```
Quantidade total de palavras >> 1141
Quantidade total de palavras únicas >> 470
```

```
if LOCAL_EXECUTION:
    df.to_csv(f'{OUTPUT_DIRECTORY}/df.csv')
    df.to_json(f'{OUTPUT_DIRECTORY}/df.json', orient='records', lines=True)
```

Plotagem dos dados

Diminuir o dataset ate a linha 170, pois a partir desta linha os valores são os mesmos e já conseguimos a representação visual que buscamos, tornando o gráfico mais legível

```
# pegar somente as primeiras 160 linhas
```

```
df = df[:171]
```

Realizar diferente plotagens dos dados selecionados

```
size_one = 50
size_two = 20

sns.set(rc={'figure.figsize':(size_one, size_two)})
sns.set(rc={'figure.figsize':(size_one, size_two)})
```

Gráfico de barras

```
sns.barplot(x=df['word'], y=df['actual_frequency'])
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f341c180d10>
```

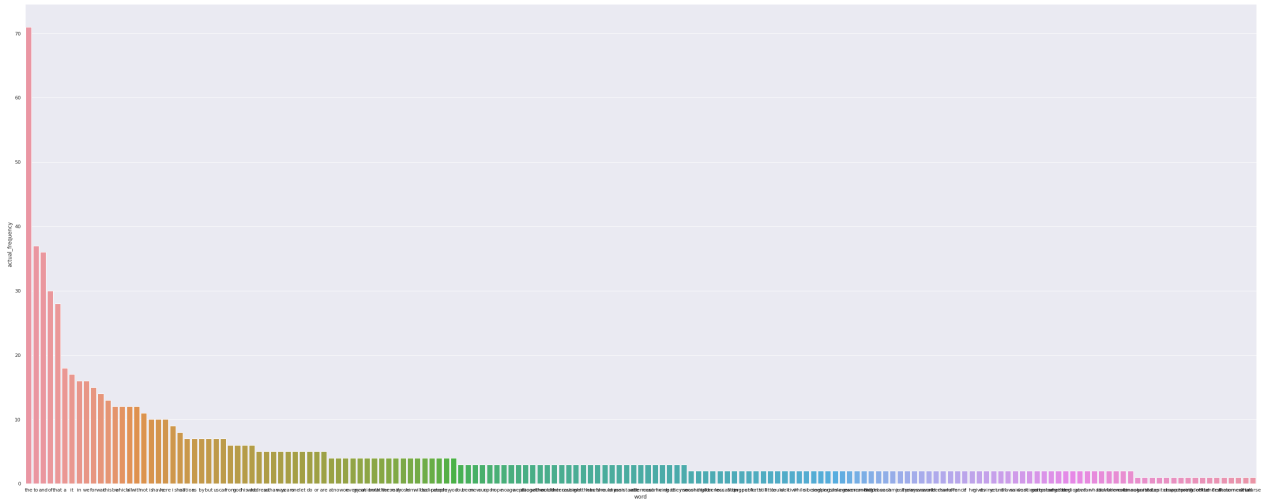

Gráfico de linha

```
1 sns.lineplot(x="word", y="actual_frequency", data=df, lw=10)
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f341b6e9ad0>
```

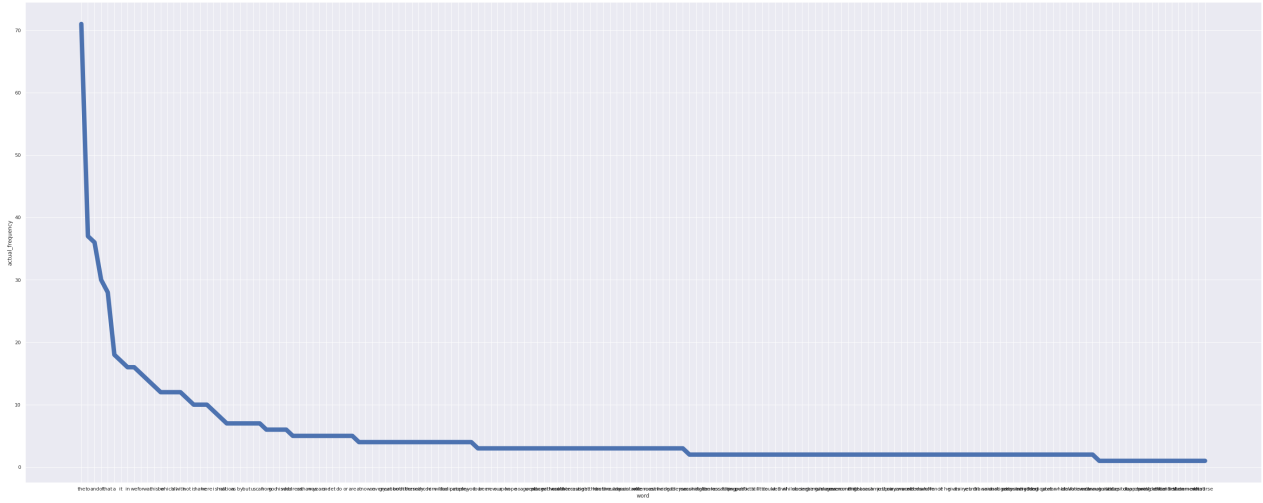

Gráfico de dispersão

```
1 sns.scatterplot(x="word", y="actual_frequency", data=df, hue='actual_frequency', palett
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f3419c93150>
```

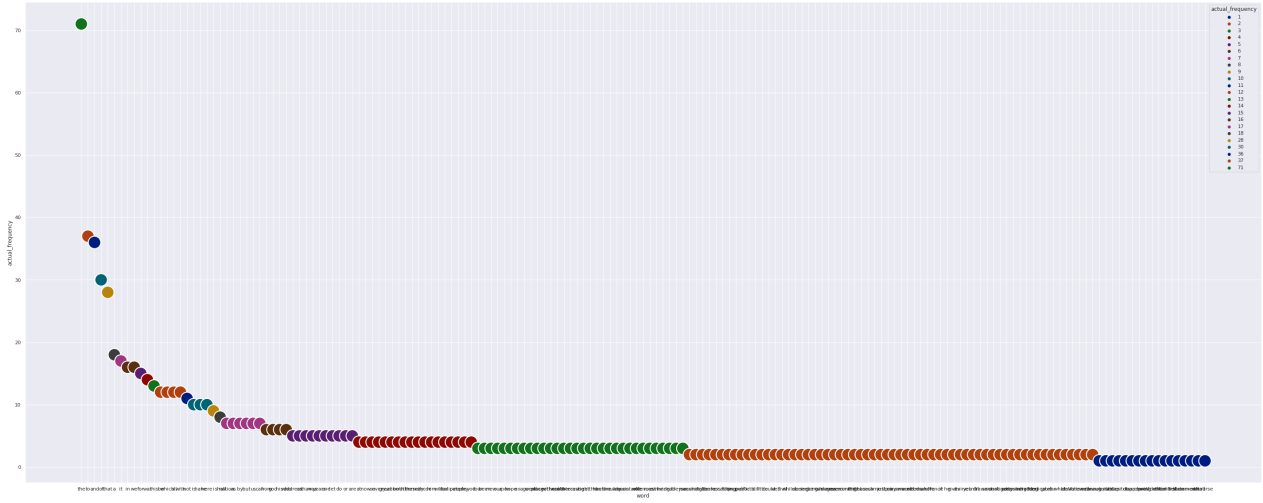

Conclusão

Como podemos observar, Os discursos de Abraham Lincoln não geram totalmente o resultado esperado pela distribuição de Zipf - Na verdade, poucos textos individuais irão atingir este objetivo.

Porém, com esta tarefa, foi atingido o objetivo de não somente entender na prática este conceito estatístico mas termos uma representação gráfica do mesmo para melhor entendimento